

2024年英才学员课题报告： 使用Python结合机器学习及大数据可视化技术开展全 球经济数据研究

北京中学国际部 李禹征

1. 研究背景

自2020年新冠疫情爆发以来，全球经济遭受了前所未有的冲击。各国纷纷采取了大规模的货币宽松和财政刺激措施来应对，随着疫情结束和社会活动的恢复，全球经济正逐步走向复苏，但挑战依旧重重。疫情结束以来，全球经济高度分化，美国经济势头强劲，以AI为代表的高科技引领新技术革命；欧亚大陆卷入纷乱，俄乌危机和中东乱局阴霾笼罩，导致多国经济增长面临严重困境，移民与难民问题此起彼伏；中国作为全球第二大经济体，在疫情后迅速采取有效措施，推行了一系列恢复经济的政策，2023年中国的GDP增长率达到了8.1%，显示出强劲的经济复苏能力，出口领域、数字经济的发展成为了新的增长亮点。主要经济体的宏观政策和商业环境正在经历深刻的变革，这种变化不仅会影响到全球财务健康，也会重塑整个世界经济的未来格局。在当前全球经济复苏的背景下，各大经济体在政策和市场环境方面的动向，吸引了无数投资者和政策制定者的关注。2024年1月4日 联合国发布的《2024年世界经济形势与展望》报告指出，利率持续高企，冲突进一步升级，国际贸易疲软，气候灾害增多，给全球增长带来巨大挑战。报告预计，全球经济增长将从2023年的2.7%放缓至2024年的2.4%，低于疫情前3%的增长率。报告认为，需加大政策权衡与国际合作，在当前全球货币条件依然紧缩的情况下，各国政府需要扩大财政支持，刺激经济增长，世界各国在实现通货膨胀、经济增长和金融稳定目标之间的平衡时，继续面临艰难权衡，尤其需要部署广泛的宏观经济和宏观审慎政策工具，以尽量减少发达经济体货币紧缩的不利溢出效应。

在上述背景下，实现有韧性的经济扩张对于提高生活质量和促进整体富裕至关重要，这个目标在很大程度上取决于有效的宏观经济策略的实施。然而，经济发展涉及驾驭很多宏观经济因素的复杂相互作用，包括通货膨胀、利率、汇率、就业、国际收支平衡等（Anaripour, 2011; Ingham, 2013; Jakob,

2015;Kibria 等人, 2014;Mamo, 2012;Svyrydenko 等人, 2023;Tapsin & Hepsag, 2014)。特别是通货膨胀, 对经济稳定和增长具有重大影响, 促使政策制定者采取旨在维持低通胀水平同时促进强劲经济表现的战略

(Zhao&Brychko, 2023, 联合国贸易和发展会议 (UNCTAD), 2019)。由于宏观经济指标之间相互联系、相互影响制约, 宏观调控的目的在于恰当处理这几方面关系。本研究旨在通过多层次的指标体系, 对各国的综合发展水平、宏观经济指标之间交互作用进行量化分析, 为宏观调控提供有益的政策参考。

基于以上背景, 本研究通过确定经济发展的关键驱动因素及其对经济表现的影响, 建立经济发展的整体评价模型, 用以研究探讨关键宏观经济指标之间的复杂相互作用。对于影响经济发展的重要关键指标, 进一步通过线性回归和时间序列分析的逐步探索, 分析各经济体 GDP 增长的差异化驱动因素及其未来趋势。本研究使用机器学习算法及面板因果关系检验来测量各种宏观经济变量与经济发展之间的关系, 试图阐明各国经济增长的复杂动态, 给出理解和利用宏观经济指标促进各国可持续经济发展的决策参考及预测模型, 通过研究各经济体的经济发展轨迹、分析各因素的影响变化为各国经济策略提供见解, 从而能够针对性改善相关指标, 来解决这些差距。

2. 经济发展综合评价指数模型的构建

2.1 建立综合评价指标体系

经济发展质量是对一个国家或地区经济发展状况的综合评价指标, 不仅关注经济增长效应, 同时也强调与经济增长联系紧密的社会效应, 是在数量型经济增长基础上的质量优劣程度的价值评判。因此, 经济发展质量指标的构建应是增长速度与稳定性、社会福利改善的综合体现, 可为中长期宏观经济政策的制定提供参考, 以实现经济社会的可持续发展。根据经济发展质量的内涵, 并参考中国统计局常用口径、世界银行全球治理指数 (Worldwide Governance Indicators, WGI)、联合国可持续发展目标 (Sustainable Development Goals, SDGs) 等指数体系设计, 本研究从经济增长、充分就业、物价稳定、国际收支平衡、社会福利五个维度构建经济发展质量指标体系, 选取了多个具有代表性的二级指标, 并将其归类到相应的一级指标下。为了使得每个一级指标的综合数据具有科学合理的权重, 采用了熵权法 (Entropy Weight Method) 对二级指标和一级指标分别进行加权和综合评分计算。

2.1.1 指标体系的构建

- 在构建综合评价体系时，根据研究需求和数据可得性，选取了以下指标：
- （1）经济增长：包含 GDP、GDP 增长率、人均 GDP、人均 GDP 增长率、国民总收入（GNI）五个二级指标。
 - （2）充分就业：以失业率为二级指标，反映国家的就业状况。
 - （3）物价稳定：采用通货膨胀率作为衡量物价稳定性的二级指标。
 - （4）国际收支平衡：以经常账户余额占 GDP 的比重为二级指标，衡量国家的国际经济稳定性。
 - （5）社会福利：以人均居民消费支出为二级指标，反映国家的福利水平。

其中，失业率和通货膨胀率为逆向指标，这意味着这些指标的数值越低代表发展越好。因此，在熵权法计算前，对这两个逆向指标进行了逆向处理，使得所有指标的方向保持一致。以下为构建完成的指标体系表：

表：经济发展质量综合评价指标体系

序号	一级指标	二级指标	指标属性
1	经济增长	GDP	正向
2		GDP 增长率	正向
3		人均 GDP	正向
4		人均 GDP 增长率	正向
5		国民总收入 GNI	正向
6	充分就业	失业率	逆向
7	物价稳定	通货膨胀率	逆向
8	国际收支平衡	经常帐户余额占 GDP 比重	正向
9	社会福利	人均居民消费支出	正向

2.1.2 二级指标的权重计算与一级指标的综合数据生成

建立了上述指标体系后，首先使用熵权法对各一级指标下的二级指标进行权重计算，以得到每个一级指标的综合数据。具体步骤如下：

- （1）数据标准化：为了消除量纲的影响，首先将每个二级指标的数据进行标准化处理。对于正向指标，标准化公式为：

$$z_{ij} = \frac{x_{ij} - x_{j,\min}}{x_{j,\max} - x_{j,\min}}$$

而对于逆向指标，处理为：

$$z_{ij} = \frac{x_{j,\max} - x_{ij}}{x_{j,\max} - x_{j,\min}}$$

其中， x_{ij} 表示第 i 个国家在第 j 个二级指标上的值， $x_{j,\min}$ 和 $x_{j,\max}$ 分别表示第 j 项指标的最小值和最大值。

(2) 计算比重和熵值：对于标准化后的二级指标，计算每个国家在该指标上的比重 p_{ij} ，并基于此计算指标的熵值 e_j ：

$$e_j = -\frac{1}{\ln(n)} \sum_{i=1}^n p_{ij} \ln(p_{ij} + \epsilon)$$

其中 ϵ 为一个极小值（如 10^{-10} ，以防止对数运算中的零值问题。

(3) 计算权重并生成一级指标的综合数据：根据熵值计算差异系数 $d_j = 1 - e_j$ ，然后得到每个二级指标的权重 $w_j = \frac{d_j}{\sum d_j}$ 。

根据这些权重对各二级指标进行加权求和，生成每个一级指标的综合数据。经济增长的综合数据为：

$$S_{\text{经济增长}} = \sum_j w_j \cdot z_{ij}$$

通过以上步骤，得到了每个一级指标（如经济增长、充分就业等）的综合数据，使其能够代表各个方面的总体情况。

2.1.3 一级指标的权重计算与最终综合评分

在得到每个一级指标的综合数据后，再次使用熵权法对一级指标赋权，并计算每个经济体的最终综合评分。具体步骤如下：

(1) 一级指标的标准化：对每个一级指标的综合数据进行标准化处理，消除量纲影响。

(2) 熵权法计算一级指标的权重：重复二级指标的计算步骤，得到一级指标权重。最终的权重分配能够反映不同方面对经济体综合发展评价的重要性。

(3) 综合评分计算：根据一级指标的权重，计算每个经济体最终综合评分：

$$S_{\text{综合评分}} = \sum_k W_k \cdot S_k$$

其中，S_k 为第 k 个一级指标的综合数据，W_k 为其对应的权重。

通过上述步骤，本研究最终得到每个经济体在不同年度的综合评分，能够反映各国在经济增长、就业稳定、物价稳定、国际收支和社会福利等多个维度的相对表现。该评分为进一步分析国家间的综合发展水平提供了量化依据。

2.2 经济发展质量综合评价结果

由于本文的研究对象是中长期结构性的经济发展，而非经济周期波动，因此将研究时段选取为最近一个康波经济周期，即2008年至2023年（资料来源：荷兰经济学家雅各布·范·杜因, 中信建投）。由于大多数国家和地区在世界银行有据可查，本文选取世界银行有数据可查的261个经济体（含各维度分类）进行分析。将各经济体各年数据代入指标体系模型后，数据可视化结果如下：

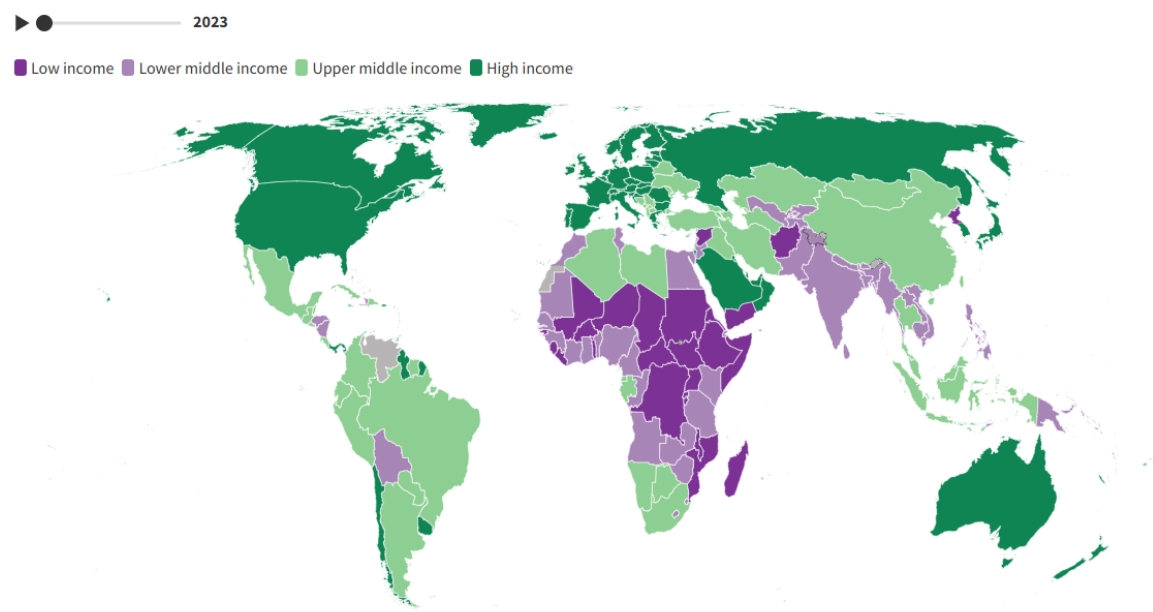
2.2.1 按 2023 年地理区域分类评价

Table 1: Score Summary (2021-2023)				
English Region	Score_2021	Score_2022	Score_2023	Average
North America	48.28	48.59	50.06	42.58
Europe & Central Asia	20.31	20.41	21.36	19.48
Small states	17.01	15.97	16.48	19.52
East Asia & Pacific	11.54	11.97	12.58	10.89
Central Europe and the Baltics	9.38	9.21	10.15	8.16
Latin America & Caribbean	7.86	7.87	8.66	7.54
Arab World	6.78	6.80	7.54	6.11
Middle East & North Africa	5.83	5.79	6.75	5.61
Sub-Saharan Africa	4.53	4.10	4.55	5.61
Africa Eastern and Southern	4.11	3.68	4.16	5.14
South Asia	2.47	2.36	2.94	2.29
Africa Western and Central	0.88	0.68	1.24	1.10

从区域看，2023年北美洲总体得分最高，其次为欧洲和中亚，得分最低为非洲中部和西部。与世界银行按收入水平划分的地区分类结果较为一致(见下图1)，总体符合世界经济各区域发展实际。

图1：世界银行2023年按收入水平划分的世界地理区域

按收入划分的世界



Source: [World Bank Group](#)
Note: (1) Countries are classified each year on July 1, the start of the World Bank fiscal year, based on GNI per capita data (World Bank Atlas method) for the previous calendar year. For FY25 the classification uses GNI per capita for 2023. (2) Map boundaries represent boundaries as of 2020 and do not change over time. Country borders or names do not necessarily reflect the World Bank Group's official position. This map is for illustrative purposes and does not imply the expression of any opinion on the part of the World Bank, concerning the legal status of any country or territory or concerning the delimitation of frontiers or boundaries.

2.2.2 按国家各年指数平均值评价

Table 2: Top 20 countries' Average Score

Country Name	Average
Virgin Islands (U.S.)	67.76
United Arab Emirates	30.54
Greenland	26.15
European Union	20.47
Puerto Rico	18.06
United States	17.58
Northern Mariana Islands	16.15
Faroe Islands	15.16
Switzerland	15.05
Bermuda	14.89
Luxembourg	12.87
Norway	11.60
Australia	11.11
United Kingdom	10.30
Iceland	9.61
Denmark	9.32
Hong Kong SAR, China	9.22
New Caledonia	9.18
Canada	9.12
Germany	8.68

Table 3: Top 49-60 countries' average

Country Name	Average
China	4.37
Monaco	4.14
Palau	4.11
Liechtenstein	4.07
Bahrain	4.01
Malta	3.95
Curacao	3.81
Seychelles	3.73
Slovak Republic	3.69
Estonia	3.63
Czechia	3.58
Lithuania	3.55

Table 4: Last 20 countries average score (2023)

Country Name	Average
Nigeria	0.80
Micronesia, Fed. Sts.	0.80
Lesotho	0.79
St. Lucia	0.79
Niger	0.79
Zambia	0.77
Maldives	0.77
Congo, Dem. Rep.	0.77
Madagascar	0.74
Papua New Guinea	0.72
Suriname	0.72
St. Vincent and the Grenadines	0.69
Kiribati	0.66
Burundi	0.64
Eritrea	0.61
Malawi	0.61
Liberia	0.60
Sao Tome and Principe	0.59
Afghanistan	0.59
Venezuela, RB	0.47
South Sudan	0.40

从国家看，为消除异常年份波动影响，选取各年平均值进行国家间比较。排名前20的国家包括美国、瑞士、卢森堡、澳大利亚、英国等发达国家；中国处于排名第49的位置，评价分值较发达国家有一定差距；排名末尾20的国家包括南苏丹、阿富汗、利比里亚等国，显示出战乱、冲突及历史沿革对国家经济发展的显著影响。

2. 2. 3 按 2023 年各类经济组织分类评价

Table 5: Score Summary (2023)

Region	Score_2023
High income	38.93
OECD members	38.00
Euro area	25.31
European Union	23.35
Middle income	10.72
Fragile and conflict affected situations	3.64
Least developed countries: UN classification	2.98
Heavily indebted poor countries (HIPC)	2.80
Low income	2.75

在各类有数据可查的经济组织分类中，世界经合组织成员国的总体得分较高，欧元区国家总体接近高收入国家水平，脆弱和受冲突局势影响的国家显现出经济困境，最不发达国家（联合国分类）与高收入国家之间差距巨大。

2008–2023年各经济体经济发展综合评价指数完整表另见附表。

3. GDP 指标线性回归分析

在经济发展质量指数中，国内生产总值（GDP）作为衡量一个国家经济进步的主要指标起着至关重要的作用（Jim-Suleiman & Adeyele, 2023年;Mollah 等人, 2022年），我们对该指标进一步展开回归分析。以计算GDP的支出法为基础，以美国为例，对取自世界银行1970年至2023年样本数据进行实证检验，选取4个重要变量来衡量研究GDP的增长，分别是固定资产投资、社会消费品总额、政府财政支出和净出口。通过构建多元线性回归模型，消除多重共线性，采用ARIMA模型捕捉GDP增长的时间序列特征，得出GDP增长模型。通过模型预测情况，政府可以得到驱动本国经济增长的最佳组合策略。

按照经济学GDP核算支出法理论，国内生产总值= 消费 + 投资 + 政府消费 + 净出口。本文选取该4 个重要变量来衡量研究GDP (Y)的增长，则GDP (Y)为被解释变量，解释变量分别是固定资产投资，用I 表示；社会消费品总额，用R 来表示；政府财政支出，用G 表示；净出口，用NX 来表示。

3.1 研究方法及步骤

通过线性回归和时间序列分析的逐步探索过程，分析一国GDP增长的驱动因素及其未来趋势。首先构建多元线性回归模型以识别主要影响因素，随后通过剔除变量减轻多重共线性问题，最终采用ARIMA模型捕捉GDP增长的时间序列特征。研究步骤和数据分析结果如下：

3.1.1 初始线性回归分析

构建一个多元线性回归模型，以分析GDP增长的驱动因素。美国作为全球最大经济体，以美国为例进行实证研究。选取美国1970年至2023年间的GDP数据作为因变量（以对数形式表示为 $\ln Y$ ），并将固定资产投资（ $\ln I$ ）、社会消费品总额（ $\ln R$ ）、政府财政支出（ $\ln G$ ）和净出口（ $\ln NX$ ）作为自变量。模型的具体形式如下：

$$\ln Y = \beta + \alpha_1 \ln I + \alpha_2 \ln R + \alpha_3 \ln G + \alpha_4 \ln NX + \epsilon$$

使用普通最小二乘法（OLS）对模型进行拟合，得到的回归结果如下：

变量	系数	标准误	t 值	P 值	95% 置信区间
const	-3.8257	2.722	-1.405	0.166	[-9.299, 1.647]
$\ln I$	0.1489	0.047	3.183	0.003	[0.055, 0.243]
$\ln R$	1.0274	0.006	184.298	0.000	[1.016, 1.039]
$\ln NX$	0.0274	0.008	3.565	0.001	[0.012, 0.043]
$\ln G$	0.0888	0.099	0.901	0.372	[-0.109, 0.287]

R^2 ：模型的 R^2 值为0.999，说明自变量对GDP增长的解释力极高。

显著性： $\ln R$ 和 $\ln NX$ 的P值小于0.05，表明其对GDP增长的影响显著，而 $\ln I$ 和 $\ln G$ 对GDP的影响不显著。

3.1.2 多重共线性问题的处理

尽管初始回归模型的拟合度很高，但我们进一步计算了各变量的方差膨胀因子（VIF）以检测多重共线性。结果显示， $\ln I$ 和 $\ln R$ 的VIF值较高，分别为

94.53和81.64，表明这两个变量之间存在强烈的多重共线性。为了减轻多重共线性问题，逐步剔除对GDP增长不显著的变量，首先剔除了lnI。剔除lnI后的回归结果为：

变量	系数	标准误	t 值	P 值	95% 置信区间
const	-3.8257	2.772	-1.380	0.174	[-9.400, 1.748]
lnR	1.0274	0.008	130.624	0.000	[1.012, 1.043]
lnNX	0.0274	0.009	3.215	0.002	[0.010, 0.045]
lnG	0.0888	0.098	0.904	0.370	[-0.109, 0.286]

VIF值：剔除lnI后，lnR的VIF降低到2.65，其他变量的VIF也都降至可接受范围内。

分析：剔除多重共线性后，lnR和lnNX仍然保持显著，lnG对GDP增长的影响仍不显著。

3.1.3 残差自相关性检查

线性回归模型拟合后，对残差进行了Durbin-Watson检验，以评估其自相关性。结果显示Durbin-Watson统计量为0.391，表明残差具有显著的正自相关性。因此，为更好地捕捉GDP增长的时间序列特征，引入ARIMA模型进行时间序列分析。

3.1.4 时间序列分析与 ARIMA 模型构建

为解决线性回归模型残差中的自相关问题，引入ARIMA模型进行时间序列分析。首先对GDP数据进行了ADF（Augmented Dickey-Fuller）检验，结果显示在经过一次差分后，时间序列达到了平稳性。采用自动选择算法确定ARIMA模型的最佳参数，最终选择ARIMA(0, 2, 1)模型，在自动选择过程中，该模型被选为AIC（赤池信息准则）最小的模型。以下显示了模型式子、系数估计和相关统计信息：

$$\Delta^2 \ln Y_t = \theta_1 \epsilon_{t-1} + \epsilon_t$$

ADF Statistic: -3.6997558553844336

p-value: 0.004116589562177651

Performing stepwise search to minimize aic

ARIMA(1,2,1)(0,0,0)[0] intercept : AIC=inf, Time=0.19 sec
ARIMA(0,2,0)(0,0,0)[0] intercept : AIC=-224.077, Time=0.03 sec
ARIMA(1,2,0)(0,0,0)[0] intercept : AIC=-228.473, Time=0.08 sec
ARIMA(0,2,1)(0,0,0)[0] intercept : AIC=inf, Time=0.11 sec
ARIMA(0,2,0)(0,0,0)[0] : AIC=-225.978, Time=0.02 sec
ARIMA(2,2,0)(0,0,0)[0] intercept : AIC=-233.729, Time=0.11 sec
ARIMA(3,2,0)(0,0,0)[0] intercept : AIC=-233.954, Time=0.15 sec
ARIMA(3,2,1)(0,0,0)[0] intercept : AIC=-238.112, Time=0.24 sec
ARIMA(2,2,1)(0,0,0)[0] intercept : AIC=inf, Time=0.20 sec
ARIMA(3,2,2)(0,0,0)[0] intercept : AIC=-236.874, Time=0.26 sec
ARIMA(2,2,2)(0,0,0)[0] intercept : AIC=inf, Time=0.14 sec
ARIMA(3,2,1)(0,0,0)[0] : AIC=-238.420, Time=0.22 sec
ARIMA(2,2,1)(0,0,0)[0] : AIC=-240.373, Time=0.11 sec
ARIMA(1,2,1)(0,0,0)[0] : AIC=-241.623, Time=0.09 sec
ARIMA(0,2,1)(0,0,0)[0] : AIC=-243.536, Time=0.05 sec
ARIMA(0,2,2)(0,0,0)[0] : AIC=-241.660, Time=0.10 sec
ARIMA(1,2,0)(0,0,0)[0] : AIC=-230.445, Time=0.03 sec
ARIMA(1,2,2)(0,0,0)[0] : AIC=inf, Time=0.19 sec

Best model: ARIMA(0,2,1)(0,0,0)[0]

Total fit time: 2.318 seconds

ARIMA 模型的最佳参数: (0, 2, 1)

ARIMA 模型摘要:

SARIMAX Results

Dep. Variable: lnY No. Observations: 52
Model: ARIMA(0, 2, 1) Log Likelihood: 123.768
Date: Sat, 02 Nov 2024 AIC: -243.536
Time: 13:33:15 BIC: -239.712
Sample: 0 HQIC: -242.080
- 52

Covariance Type: opg

	coef	std err	z	P> z	[0.025	0.975]
ma.L1	-0.8455	0.088	-9.618	0.000	-1.018	-0.673
sigma2	0.0004	5.27e-05	7.672	0.000	0.000	0.001

Ljung-Box (L1) (Q): 0.01 Jarque-Bera (JB): 18.63
Prob(Q): 0.92 Prob(JB): 0.00

Heteroskedasticity (H): 2.54 Skew: -0.15
Prob(H) (two-sided): 0.06 Kurtosis: 5.98

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

其中， $ma.L1$ 为一阶移动平均项系数，表示该模型包含一阶的移动平均项。 $ma.L1$ 的值为 -0.8455 ，这表明ARIMA模型中的一阶移动平均项对 $\ln Y$ 具有显著影响（P值小于0.05）。 σ^2 （方差）的估计值为 0.0004 ，表明模型的残差方差较小。

3.1.5 模型拟合与预测

基于ARIMA(0, 2, 1)模型，对GDP增长数据进行了拟合和预测，得到未来5年的预测值如下：

时间点52: 30.87

时间点53: 30.91

时间点54: 30.96

时间点55: 31.00

时间点56: 31.04

这些预测值可以用作未来GDP的增长趋势估计。

3.1.6 残差诊断与模型评价

为确保ARIMA模型的可靠性，对模型残差进行Ljung-Box检验，p值为0.562，结果显示残差无显著自相关性，这意味着模型的拟合效果良好。此外，Jarque-Bera 检验p值为0.00，表明残差不符合正态分布，这可能是由于数据本身的特性或非正态分布所致，但不会严重影响预测结果。尽管Jarque-Bera检验结果显示残差偏离正态分布，但这一偏离对预测结果的稳健性影响较小。从输出结果来看，ARIMA模型已成功拟合，ARIMA(0, 2, 1)模型成功捕捉了 $\ln Y$ 的时间序列特征，并生成了未来的预测值。残差自相关性检测表明模型拟合效果良好。

4. 结论

宏观经济指标作为宏观经济调控的依据，是处理好保持经济平稳较快发展、调整经济结构和管理通胀预期三者之间关系的重要基础。本研究基于熵权

法构建了经济发展质量综合评价指数模型，用以研究探讨宏观经济指标之间的复杂相互作用，通过来自世界银行的 2008年至 2023 年的面板数据实证研究，评价不同的宏观经济变量如何影响经济体的经济发展，旨在解决影响各国经济发展质量的关键问题，对政策制定者给予决策参考。同时为深入探索不同经济体独特的经济发展差异性，进一步构建多元线性回归模型，采用ARIMA模型捕捉GDP增长的时间序列特征，以美国为例，选取1970-2023年经济数据为输入开展研究，其结果揭示了GDP 增长与关键变量之间直接的、具有统计学意义的关联，为政府政策制定者和利益相关者提供了参考和见解。通过衡量各关键驱动因素对本国经济表现的影响，政府可以通过模型预测情况，得到驱动本国经济增长的最佳组合策略。

本研究适用于不同的经济体，从动态上对国家经济发展状况进行了反映，揭示了一个国家的优先发展项，为世界各国制定发展政策提供了一定依据，从而有助于挖掘经济发展潜力。通过分解经济发展指数，可以发现经济发展中的薄弱环节，为经济发展提供预警。各国可以参考本国各指标评分情况、GDP线性回归模型对本国经济政策做出整体把控，在弱于平均表现的方面开展政策引导，通过调节关键指标区间达到经济发展的理想状态。总之，本研究阐明了各国经济发展的复杂动态，提供了运用宏观经济指标调控促进国家可持续发展的政策工具。

5. 存在问题及后续思路

在本研究中也发现，综合评价指标体系存在局限性。首先，无论跨国家还是跨时间比较，所有国家的分数、一个国家在一段时间内的评价得分都存在标准误差。这些标准误差反映了一个国家可用的数据源的数量以及这些数据源之间的一致程度（来源越多，协议越多，标准误差越小），由于衡量方法都涉及不精确性，因此在进行跨国和长期比较时需要谨慎操作。其次，目前指标选取是基于较易获取的数据及简化操作，无法准确全面反映现实。在后续研究中应增加更多的变量，基于基本方法论对不同的经济体制定不同精度的指数体系，才能在各个分类维度下更好地衡量及进行可比性分析。再次，评价结果易受极大值和极小值的影响产生偏差。各经济体具有不同的社会人口结构、经济规模和经济结构，在综合指数权重中难于体现这些差异。因为采用将实际值与理想值和最小值联系起来的方式，来评价相对发展水平，当理想值或最小值发生变化时，即使一国的各指标值不变，其评价值也可能发生变化。后续的改进方向，可以采取聚类分析方法对相

同分类经济体进行不同指数参照值的指标体系设计，以合理调整综合指数权重。对于不同国家在制定本国经济政策时，可以进一步通过线性回归模型更准确计算本国经济发展各因素相关影响系数，以确定宏观调控政策目标及最佳平衡点。

参考文献

- [1] 2024 年世界经济形势与展望. 联合国, 2024. 1
- [2] 世界经济展望. 国际货币基金组织, 2024. 7
- [3] 全球经济展望. 世界银行, 2024. 6
- [4] 罗思义, Roy Singham, Gisela Cernadas. 210 个经济体大数据, 惊现世界和中国经济增长的密码. 观察者网, 中国人民大学重阳金融研究院, 2024. 10. 5
- [5] 陈建奇 张原. G20 主要经济体宏观经济政策溢出效应研究. 世界经济研究, 2013. 12. 18
- [6] Lucas Milanez de Lima Almeida, Paulo Antonio de Freitas Balanco. Application of multivariate analysis as complementary instrument in studies about structural changes: An example of the multipliers in the US economy. Structural Change and Economic Dynamics Volume 53, June 2020
- [7] Arman Pourghaz, Ehsan Bahrami Samani, Babak Shokri Authors Info & Claims. Analysis of the impact of research output on economic growth with using a multivariate random effects model. Scientometrics, Volume 128, Issue 4, 2023. 2. 11
- [8] 刘新建. 多因素影响分析的理论与方法. 燕山大学经济管理学院
- [9] 李文悦, 李俊刚. 基于线性回归模型对我国的 GDP 增长进行实证分析. 统计学与应用, 2022, 11 (6)
- [10] 郭卫军, 黄繁华. 经济自由度的增加能否提高经济增长质量——基于 G20 国家面板数据的实证研究. 国际贸易问题, 2019 年第 12 期
- [11] Wayne Xin Zhao, Kun Zhou*, Junyi Li*, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, Yifan Du, Chen Yang, Yushuo Chen, Zhipeng Chen, Jinhao Jiang, Ruiyang Ren, Yifan Li, Xinyu Tang, Zikang Liu, Peiyu Liu, Jian-Yun Nie and Ji-Rong Wen. A Survey of Large Language Models. A Survey of Large Language Models. arXiv:2303.18223v13 [cs.CL] 24 Nov 2023
- [12] 周志华. 机器学习. 清华大学出版社, 2016

- [13] Peter Harrington, Machine Learning in Action, Manning Publications, 2012
- [14] Sebastian Raschka, Vahid Mirjalili, Python Machine Learning (2nd edition), Packt Publishing, 2017
- [15] Andreas C. Mueller, Sarah Guido, Introduction to Machine Learning with Python, O’ Reilly Media, 2016
- [16] Jake VanderPlas, Python Data Science Handbook
- [17] <https://jakevdp.github.io/PythonDataScienceHandbook/>